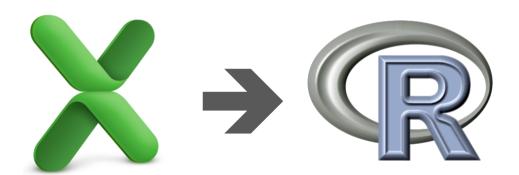


Comment avantageusement remplacer Excel par R pour traiter (automatiquement) vos fichiers de log



> Philippe kernevez



Agenda

> 5': Objectifs et contexte

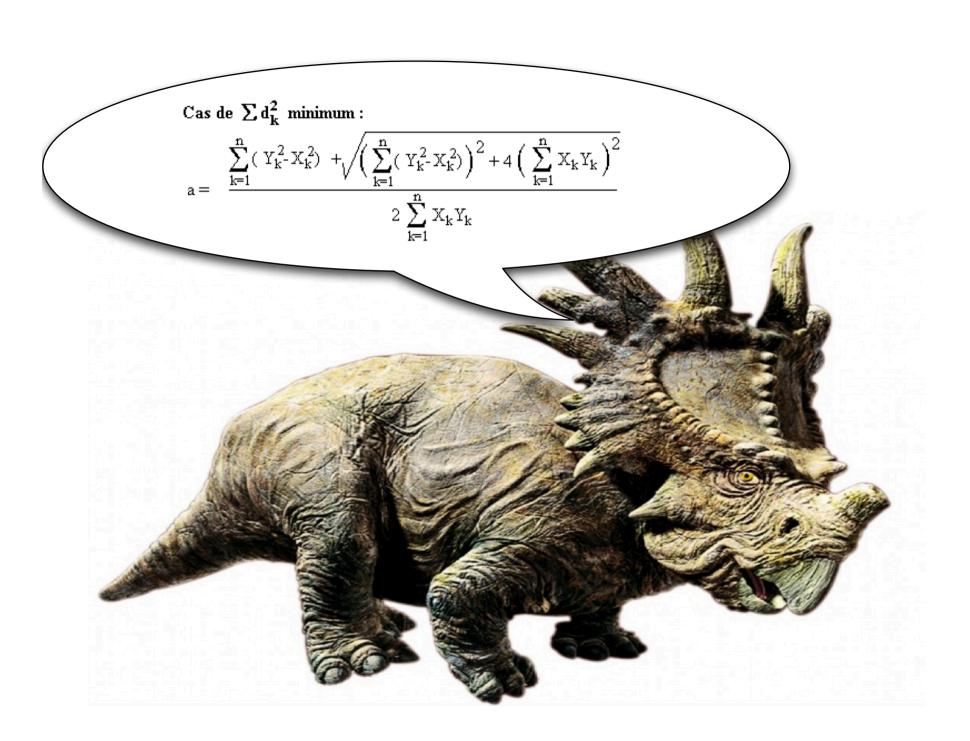
> 10': démonstration

- R est un dialecte du langage S
- > S inventé en 1976 au Bell Labs pour de l'analyse statistique en remplacement de FORTRAN.
- > R a été lancé en 1991
 - + Licence GNU depuis 1995
 - + 2000 : R v 1
 - + 2012 : R v 2.5version 2.15.1
- > R http://www.r-project.org/



> Rstudio http://www.rstudio.com/







Besoins

> Contexte



> Question

- Ma journée d'hier était-elle représentative ?
- + A quelle heure mes temps de réponse se sont dégradés ?
- + Mes temps de réponse changent-ils en fonction de la charge ?

Les solutions...

- + Shell (grep / sed)
- + Script (Groovy)
- + Excel

- Ca fonctionne mais...
 - + Excel peine à afficher les graphiques de plusieurs milliers de points
 - + C'est fastidieux
 - Utilisations de tableaux croisés dynamiques pour les moyennes glissantes
 - Du 'bricolage' pour avoir des quantiles glissants
 - + Cela reste manuel

+ Shell (grep / sed)

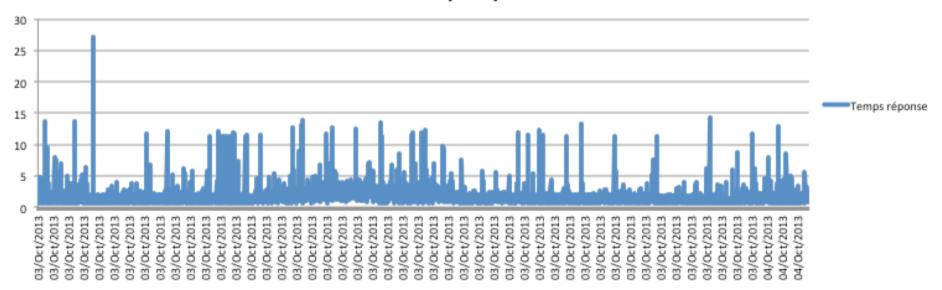
+ R



Exemples

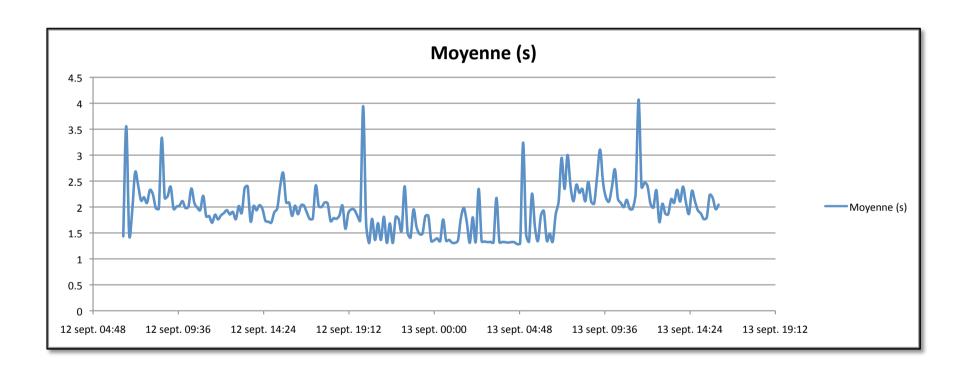
- > Evolution du temps de réponse au cours du temps
 - + Exemple sur mon poste
 - 20'000 points avec Excel: 2 minutes
 - 330'000 points avec R: 6s

Temps réponse

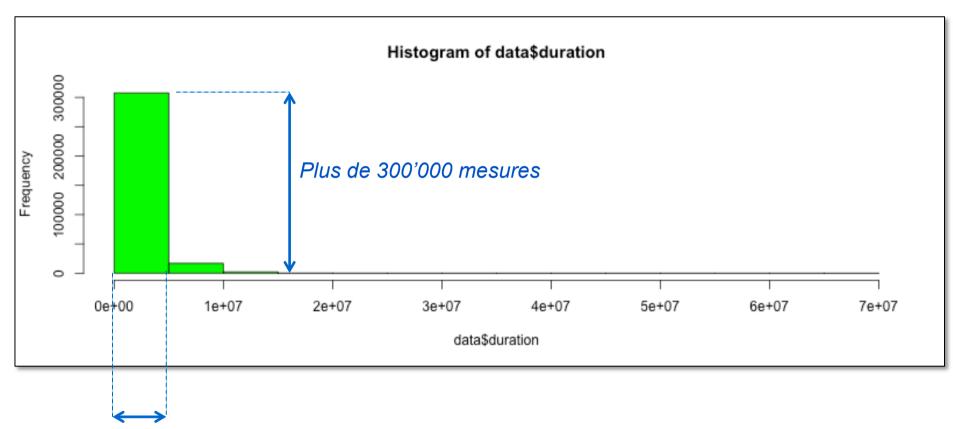


Exemples

- > Moyenne ou percentile glissant
 - + Percentile 95 : 95% des requêtes en moins de X s

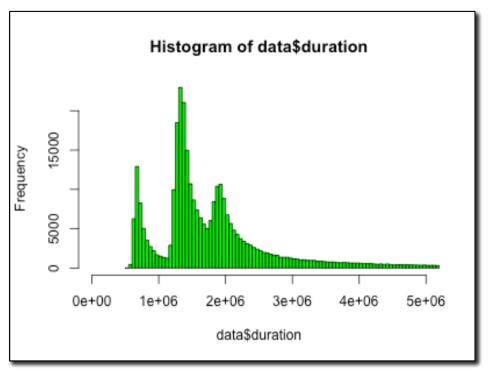


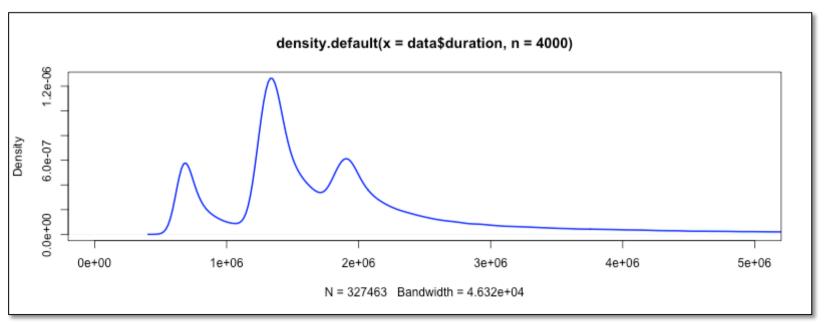
Histogramme



En moins de 5e+6 μs (0.5s)

Distribution







Pour finir

- > Limites
 - + Tailles des objets en mémoire
 - + Formatage des dates
 - La solution est d'utiliser les timeseries (xts)
- Toutes les infos sur
 - https://github.com/pkernevez/RQuicky.git
- > Alternative
 - Kibana (elasticsearch)
- > Pour démarrer
 - http://www.r-project.org/
 - + Coursera https://class.coursera.org/reactive-001/assignment